


Instituto Tecnológico y de Estudios Superiores de Monterrey



Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador: Análisis y Pronóstico Epidemiológico de la Enfermedad de Alzheimer en México (2014–2024)

Actividad 6. Conclusiones Clave

Equipo 22:

Jorge Steven Reyes Londono A01794421

Pablo Yamamoto Magaña A01022382

Aarón Cortés García A01730451

Profesores:

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

02/11/2025

ACTIVIDAD 6. CONCLUSIONES CLAVE

Viabilidad y Conclusiones Clave del Proyecto de Pronóstico.

Tras una exhaustiva fase de experimentación y modelado, hemos llegado a una serie de conclusiones fundamentales sobre la viabilidad de un sistema de pronóstico para los nuevos casos de Alzheimer. El desarrollo de esta solución presentó un desafío considerable, no solo por la complejidad inherente al pronóstico de series de tiempo, sino también por la naturaleza de los datos fuente, que son naturalmente volátiles y han sido impactados por eventos disruptivos sin precedentes.

→ El Desafío Metodológico: El Pivote de la Granularidad.

La hipótesis inicial del proyecto era desarrollar un modelo de alta granularidad, con la capacidad de pronosticar a nivel de entidad federativa e incluso por género. Sin embargo, un análisis riguroso en las primeras etapas de la experimentación demostró que este *approach* no era el más favorable.

Al aislar las series de tiempo a este nivel de detalle (ej. "Colima - Hombres"), nos encontramos con que la gran mayoría de los registros semanales eran cero. Estas series de tiempo "dispersas" (*sparse*) carecían de una "señal" estadística suficiente (tendencia o estacionalidad claras) para que un modelo como Prophet pudiera ser entrenado de manera confiable. Los modelos resultantes tendían a predecir líneas planas, y las métricas de error porcentual (MAPE) se volvían estadísticamente inválidas al dividirse entre cero.

Por esta razón, se tomó la decisión metodológica de pivotar hacia un modelo agregado a nivel nacional. Al sumar todos los estados, el "ruido" de las entidades individuales se canceló, revelando una serie de tiempo nacional más "rica", con patrones de tendencia y estacionalidad que sí podían ser modelados de manera más eficaz.

→ Rendimiento del Modelo y Evaluación del Pronóstico.

El modelo final seleccionado se desarrolló utilizando la serie nacional, entrenando con los datos "limpios" y estables de 2014 a 2022. Esta decisión se tomó tras descubrir que incluir los datos "ruidosos" de 2023-2024 en el entrenamiento empeoraba el rendimiento. El modelo se configuró para aislar el impacto de la pandemia como un evento anómalo de 2.5 años.

Para evaluar la robustez de este modelo, se le sometió a una prueba de estrés: generar un pronóstico a largo plazo de 3 años (2023, 2024 y 2025) y comparar estas predicciones con los datos reales.

Antes de presentar los resultados, es importante entender las métricas de evaluación:

- MAPE (Error Porcentual Absoluto Medio): El error promedio en términos de porcentaje. Es la métrica más interpretable para la planeación.
- MAE (Error Absoluto Medio): El error promedio en el número de casos. Ejemplo - Un MAE de 8 significa que, en una semana promedio, la predicción estuvo 8 casos por arriba o por abajo del número real.
- RMSE (Raíz del Error Cuadrático Medio): Similar al MAE, pero penaliza más los errores grandes. Un valor cercano al MAE es una buena señal de que el modelo es estable y no comete fallos catastróficos.

Los resultados de esta evaluación multianual fueron los siguientes:

Período de Evaluación	MAPE	MAE	RMSE
2023 (Año 1)	15.38%	7.81	9.35
2024 (Año 2)	17.57%	7.11	8.46
2025 (Año 3)	15.97%	6.54	8.91
Promedio Total (2023-2025)	16.34%	7.20	8.91

A pesar de que las métricas no son excepcionales, se tiene el factor favorable de que el error no se "acumuló" ni "explotó" con el tiempo (el grado de error en el Año 3 fue cercano al encontrado en el Año 1), lo que demuestra que el modelo capturó la tendencia fundamental de la serie de forma correcta.

➔ Viabilidad y Potencial de Mejora.

Consideramos que el rendimiento actual del modelo es lo suficientemente bueno para su implementación como herramienta de planeación estratégica, representando una base sólida para la planeación macro a nivel anual o semestral, permitiendo al IMSS anticipar la tendencia general de crecimiento con un rango de error conocido. Sin embargo, este nivel de error aún es demasiado alto para una implementación operativa (semanal) de alta precisión.

El potencial de mejora puede residir en la agregación de otros modelos predictivos o factores de ajuste, que se sumen a las hechas por Prophet, para buscar reducir el rango de error. Sin embargo, otra área de mejora recae en la calidad de los datos fuente. El "ruido" identificado en 2023-2024 y las inconsistencias históricas representaron un cuello de botella para la precisión.

→ Recomendaciones Clave para la Implementación.

- Fase 1: Implementación como Piloto de Planeación Estratégica. Recomendamos implementar el "Modelo Final" (entrenado en 2014-2022) como un *dashboard* de planeación macro-anual. Su capacidad para proyectar la tendencia a 1-3 años es valiosa para la planeación de presupuestos y la asignación de recursos a alto nivel.
- Fase 2: Proyecto de Gobernanza y Calidad de Datos. La implementación de la Fase 1 debe ir en paralelo con un proyecto de mejora de la calidad de los datos históricos. Esto implica una colaboración estrecha entre el equipo técnico y los expertos de dominio del IMSS para auditar y corregir posibles datos fuente.
- Fase 3: Re-entrenamiento y Modelado Granular. Una vez que los datos a nivel estatal sean confiables (resultado de la Fase 2), se puede re-evaluar la optimización del modelo nacional y replantear el *approach* de 32 modelos independientes, que sigue siendo el objetivo final para un pronóstico a nivel de entidad.

→ Tareas Accionables para los Stakeholders.

Para el IMSS (Expertos de Dominio):

- Validar Hallazgos: Confirmar formalmente las hipótesis del equipo técnico (ej. "Sí, los datos de 2023-2024 presentan un cambio considerable de comportamiento conforme al histórico pre-pandemia").
- Iniciar la Gobernanza de Datos: Esta es la tarea accionable más crítica para mejorar la precisión del pronóstico. Asignar un equipo o responsable para comenzar la auditoría y revisión de los boletines históricos en colaboración con la Secretaría de Salud.
- Definir el Criterio de Éxito Considerando Limitantes Encontradas: Definir formalmente cuál es el MAPE o MAE aceptable para que el modelo se considere "listo para producción" (ej. ¿12%? ¿10%?).

Para el Equipo Técnico (Equipo de Ciencia de Datos / ML):

- Empaquetar el Piloto (Fase 1): Desarrollar el *script* o *dashboard* del modelo seleccionado que genere el pronóstico nacional a 52 semanas.
- Documentar las Limitaciones: Crear la documentación que explique claramente lo que el modelo hace, lo que no hace, y sus limitaciones (ej. "Este modelo no debe usarse para predicciones semanales operativas").

- Establecer un Protocolo de Monitoreo: Diseñar el sistema que, una vez en producción, mida continuamente el error del pronóstico contra los nuevos datos reales que vayan siendo registrados.

Evaluación Comparativa de Proveedores.

→ Amazon Web Services (AWS)

AWS ofrece Amazon SageMaker con soporte nativo para Prophet y capacidades de optimización automática de hiperparámetros. Cuenta con el ecosistema más maduro del mercado (32% cuota global) e integración con S3 compatible con DVC. Sin embargo, presenta alta complejidad operacional y costos significativos: ~\$1,196 por 100 horas de entrenamiento o \$8,611/mes para deployment continuo.

Ventajas: Mayor documentación, comunidad extensa, flexibilidad de deployment, métricas de forecasting integradas (MASE, sMAPE, RMSE).

Limitaciones: Curva de aprendizaje pronunciada, estructura de costos compleja, configuración inicial requiere expertise avanzado.

→ Microsoft Azure

Azure Machine Learning Studio proporciona una plataforma unificada con interfaz más intuitiva que AWS. Ofrece integración nativa con Power BI y Excel, útil para reportería institucional. Costos similares a AWS (~\$1,196 por 100 horas) pero con menor cantidad de recursos específicos para Prophet.

Ventajas: Menor complejidad operacional, fuerte soporte para entornos gubernamentales, modelo de precios más predecible.

Limitaciones: Ecosistema de forecasting menos desarrollado, documentación limitada para casos académicos.

→ Google Cloud Platform (GCP)

Vertex AI ofrece la interfaz más intuitiva con menor curva de aprendizaje. Vertex AI Forecast está optimizado para series temporales con algoritmos como ARIMA+. Sin embargo, presenta costos elevados: \$21.25/hora entrenamiento y \$5 por 1,000 predicciones batch.

Ventajas: Servicios consolidados, especialización en AutoML, documentación clara.

Limitaciones: Menor ecosistema de terceros, optimizado para grandes volúmenes, costos altos para proyectos pequeños.

→ IBM Watson Studio

Watson Machine Learning ofrece plan Lite gratuito (20 CUH/mes) adecuado para evaluación. Planes pagos desde \$1,050/mes, significativamente más costosos que otros competidores. Menor adopción en el mercado y documentación limitada para Prophet.

Ventajas: Opción gratuita viable, certificación HIPAA para datos de salud.

Limitaciones: Costos empresariales prohibitivos, comunidad pequeña, ecosistema reducido.

Análisis de Factores Críticos

Facilidad de uso	GCP presenta menor barrera de entrada, Azure ofrece balance intermedio, AWS requiere mayor capacitación.
Escalabilidad	Los tres principales proveedores ofrecen escalabilidad prácticamente ilimitada, aunque no es factor determinante para datasets de 14KB.
Servicios específicos	AWS SageMaker lidera en integración documentada con Prophet y métricas de forecasting solicitadas (sMAPE, MASE, RMSE).
Costos	Rango de \$1,196-\$8,611/mes (AWS/Azure), \$21.25/hora (GCP), o \$1,050/mes mínimo (IBM). Todos resultan prohibitivos para proyectos académicos sin presupuesto.

Justificación y Análisis del Contexto del Proyecto

La evaluación exhaustiva de los cuatro proveedores cloud revela que la implementación en plataforma cloud no representa la solución más adecuada para este proyecto específico. Esta conclusión se fundamenta en el análisis de las características particulares del proyecto:

Características del proyecto:

- Dataset procesado: 14KB (raw: 10MB)
- Modelo: Prophet entrenado, estático, para pronósticos esporádicos
- Usuarios: Sin definición de concurrencia ni SLA requeridos
- Presupuesto: No asignado para infraestructura cloud
- Tecnología: Framework open-source que no requiere cloud para operar

Recomendación: Solución Basada en Repositorio GitHub

Se recomienda mantener la solución en repositorio GitHub con ejecución local mediante Jupyter Notebooks, fundamentado en criterios técnicos, económicos y operacionales.

→ Justificación Técnica

El modelo Prophet es un framework open-source desarrollado por Meta que no requiere infraestructura cloud para su operación. El modelo entrenado puede serializarse (formato pickle o joblib) y almacenarse directamente en el repositorio sin degradación de performance. Los 14KB de datos procesados están significativamente por debajo del límite de GitHub (100MB por archivo), permitiendo versionamiento completo sin necesidad de soluciones de almacenamiento externo.

Los notebooks de Jupyter documentan completamente el pipeline de entrenamiento y predicción, proporcionando trazabilidad y reproducibilidad científica esenciales para validación académica. No existen requisitos de latencia (<100ms), disponibilidad (99.9% uptime) o concurrencia (>10 usuarios simultáneos) que justifiquen la complejidad de endpoints REST dedicados o arquitecturas serverless.

La arquitectura propuesta (repositorio + ejecución local) cumple perfectamente con los objetivos del proyecto: generar pronósticos de 13/26/52 semanas con métricas MASE, sMAPE y RMSE, y entregar reportes con KPIs para planeación operativa del IMSS. El dashboard de Tableau ya

implementado puede leer resultados exportados en CSV desde ejecuciones locales, manteniendo la visualización institucional requerida.

→ Justificación Económica

El análisis de costos demuestra una desproporción significativa entre la inversión requerida en cloud y el valor generado para este proyecto específico:

- AWS: \$1,196 por 100 horas de entrenamiento (modelo ya entrenado) o \$8,611/mes para endpoint dedicado
- Azure: Costos similares (~\$1,196 por 100 horas de VMs)
- GCP: \$21.25/hora entrenamiento; \$5 por 1,000 predicciones batch
- IBM Watson: Planes desde \$1,050/mes (plan gratuito insuficiente para deployment real)

Proyectando un escenario conservador de 4 ejecuciones mensuales para generar pronósticos trimestrales, AWS serverless costaría ~\$120-240 anuales (Lambda + API Gateway + S3). Aunque relativamente bajo, este costo debe compararse contra el costo cero de la solución en repositorio, considerando que:

- El proyecto no tiene presupuesto asignado
- No existe garantía de financiamiento futuro por parte del IMSS
- La naturaleza académica no requiere SLA de producción
- El modelo no requiere reentrenamiento automatizado

La solución en repositorio elimina costos de infraestructura, licenciamiento, mantenimiento, monitoreo y troubleshooting, garantizando sostenibilidad financiera indefinida sin comprometer funcionalidad.

→ Justificación Operacional

Desde la perspectiva operacional, la solución en repositorio presenta ventajas decisivas:

- **Curva de aprendizaje:** El equipo ya desarrolló completamente el proyecto en Jupyter/Python/Prophet, eliminando necesidad de capacitación adicional en servicios cloud (SageMaker, Vertex AI, etc.) que requieren semanas de aprendizaje. La continuidad tecnológica reduce riesgos de implementación y acelera la entrega al IMSS.
- **Independencia de proveedores:** La solución evita vendor lock-in, permitiendo portabilidad completa. El IMSS puede ejecutar pronósticos en cualquier máquina con Python 3.x instalado (Windows, Linux,

macOS), sin restricciones de región, zona de disponibilidad o términos de servicio de terceros.

- **Flexibilidad y control:** Modificaciones futuras (nuevas variables, cambios en horizonte de pronóstico, ajustes de hiperparámetros) se implementan directamente en código sin limitaciones de APIs propietarias o capacidades de plataforma. El control total sobre datos y modelos garantiza compliance implícito con regulaciones de privacidad sin necesidad de auditorías de terceros.
- **Mantenimiento simplificado:** Sin infraestructura cloud, se eliminan tareas de monitoreo de servicios, gestión de permisos IAM, rotación de credenciales, actualizaciones de runtime, parches de seguridad y troubleshooting de red. El mantenimiento se limita a actualizaciones de dependencias Python (pandas, Prophet) mediante requirements.txt.

Arquitectura Implementada

La solución propuesta consiste en:

Repositorio GitHub: Código fuente, notebooks, modelo serializado (.pkl), datos procesados (14KB CSV) y documentación completa (README.md)

Ejecución local: Jupyter Notebook o JupyterLab para generar pronósticos bajo demanda del IMSS

Exportación resultados: CSV con pronósticos 13/26/52 semanas y métricas (MASE, sMAPE, RMSE)

Visualización: Dashboard Tableau (ya implementado) leyendo CSVs exportados

Dependencias: Archivo requirements.txt con versiones específicas (pandas, prophet, numpy, matplotlib) para reproducibilidad

Flujo operacional para el IMSS:

- Clonar repositorio: git clone
<https://github.com/greyngs/alzheimer-forecasting-mexico>
- Instalar dependencias: pip install -r requirements.txt
- Ejecutar notebook: forecast_alzheimer.ipynb
- Obtener resultados: output/forecast_results.csv
- Actualizar dashboard Tableau con nuevos datos

Este flujo requiere ~10 minutos de ejecución en hardware estándar (laptop con 8GB RAM), suficiente para necesidades institucionales.

Conclusión

La evaluación exhaustiva de AWS, Azure, GCP e IBM Watson demuestra capacidades robustas de ML en los cuatro proveedores. Sin embargo, para un proyecto con datos de 14KB, modelo estático Prophet y uso esporádico, ninguna plataforma cloud representa una solución costo-efectiva ni técnicamente necesaria.

La decisión de mantener la solución en repositorio GitHub con ejecución local responde a principios de ingeniería pragmática: optimizar recursos, eliminar complejidad innecesaria y alinear la arquitectura con las necesidades reales del IMSS. Esta aproximación no sacrifica calidad en pronósticos, métricas o capacidad de visualización, mientras garantiza sostenibilidad financiera y reproducibilidad académica.

La solución propuesta representa la elección técnica y económicamente correcta, demostrando que la mejor implementación no siempre requiere infraestructura cloud, sino adecuación precisa entre tecnología y contexto de uso.