



Tecnológico de Monterrey

Proyecto Integrador (Gpo 10)

OSCAR MAURICIO BECERRA ALEGRÍA | A01795611

VÍCTOR DANIEL BOHÓRQUEZ TORIBIO | A01794554

ALAN JASSO ARENAS | A01383272

EQUIPO 20

Avance 7. Resumen ejecutivo

Profesor: Dra. Grettel Barceló Alonso

9/11/2025

Índice

Introducción.....	3
Antecedentes.....	4
Entendimiento del negocio.....	5
Formulación del problema.....	5
Contexto.....	5
Objetivos.....	5
Preguntas clave.....	6
Involucrados.....	7
Entendimiento de los datos y descripción de los datos.....	7
Convenios.....	8
Hallazgos importantes de análisis exploratorio.....	9
Limpieza de dataset.....	9
Gráficos relevantes obtenidos durante análisis.....	11
¿Existe correlación entre las variables?.....	13
ANOVA.....	14
Adición de variables exógenas.....	16
Modelos generados y selección de modelo final.....	18
Modelos generados.....	18
Modelo final: Prophet.....	21
Modelo nacional (IMSS–Parkinson México).....	22
Gráficas.....	23
Modelo por entidades federativas.....	26
Gráficas.....	28
Recomendaciones clave para implementación de solución.....	29
Acciones por stakeholders.....	30
Plataforma de nube: análisis comparativo.....	31
Plan de despliegue (propuesto).....	32
Análisis costo-beneficio.....	33
Análisis de costos incurridos - CRISP ML.....	33
Comprensión de negocios y datos.....	33
Ingeniería de datos.....	33
Ingeniería de modelos de aprendizaje automático.....	34
Evaluación de modelos.....	35
Despliegue e implementación.....	35
Monitoreo y mantenimiento.....	36
Costo total del proyecto (Sin mantenimiento).....	36
Beneficios del proyecto.....	37
Riesgos y desafíos de la solución.....	37
Conclusiones.....	40
Referencias.....	41

Introducción

En México existen diferentes enfermedades neurológicas y trastornos mentales que dañan la integridad de las personas, así como los que padecen de estas cómo de sus familiares al ver las afectaciones que le ocasionan al familiar y ver el cómo avanza con el paso del tiempo. La enfermedad de Parkinson es una enfermedad crónico-degenerativa que afecta la movilidad y la coordinación motriz de la persona, teniendo movimientos involuntarios. Es una enfermedad que no tiene cura, es progresiva y degenerativa en donde los principales afectados son hombres.

El Parkinson genera en los pacientes movimientos involuntarios, pérdida de coordinación y equilibrio, así como tener una mayor rigidez muscular y temblores. Los síntomas al inicio pueden parecer algo sencillo y casi imperceptible, como un movimiento ligero en alguna mano, pie o mandíbula. Esta enfermedad tiene como causas que algunas neuronas mueren o se degradan progresivamente.

La disminución de dopamina es la principal causa para la generación de la degradación de las neuronas y de su posible muerte, causando actividad cerebral irregular. Los pacientes que padecen de Parkinson, pierden también un neurotransmisor llamado norepinefrina, la cual controla varias funciones del cuerpo.

En este proyecto se busca generar un análisis y un modelo predictivo mediante una base de datos proporcionado por Instituto Mexicano del Seguro Social (IMSS) para poder generar un apoyo a los pacientes y futuros pacientes para poder tomar decisiones, conocer mejor los casos y ver de poder identificar quienes podrían padecer de esta enfermedad.

Antecedentes

El Proyecto de análisis y pronóstico epidemiológico de enfermedades neurológicas y trastornos mentales en México, con énfasis en la enfermedad de Parkinson (EP) durante 2014–2024, se desarrolla en el Instituto Mexicano del Seguro Social (IMSS), a través de la División de Vigilancia Epidemiológica. El IMSS es el principal prestador público de servicios de salud y protección social en el país y, mediante IMSS-Bienestar, extiende la cobertura a la población sin seguridad social. Actualmente, atiende a 53.2 millones de personas, lo que representa alrededor del 80% de la población sin seguridad social en los estados federalizados. Su infraestructura incluye 669 hospitales y 11,935 centros de salud en 28 estados, respaldados por 274,977 trabajadores de la salud (IMSS, 2024).

En el ámbito sanitario, la EP constituye uno de los principales retos de salud pública a nivel mundial. Es la segunda enfermedad neurodegenerativa más frecuente después del Alzheimer y una de las de mayor crecimiento en las últimas décadas, impulsada por el envejecimiento poblacional, factores ambientales y el aumento en la esperanza de vida (Dorsey & Bloem, 2018; GBD Parkinson's Disease Collaborators, 2018).

En México, evidencia reciente del consorcio MEX-PD indica que la incidencia en población ≥ 20 años es de 9.48 casos por cada 100,000 personas - años, con una edad promedio al diagnóstico de 59.9 años y una proporción de inicio temprano (antes de los 50 años) cercana al 21% (Lázaro-Figueroa et al., 2023). Estos resultados reflejan la tendencia ascendente de la enfermedad en la última década, confirmando la relevancia y urgencia del problema en el contexto nacional.

En este marco, el proyecto aprovecha series históricas semanales 2014–2024 generadas en el IMSS para caracterizar patrones de la EP y construir modelos predictivos que anticipen su comportamiento por entidad federativa. Esta aproximación no solo busca generar valor predictivo, sino también detectar factores de riesgo, emitir alertas tempranas y apoyar a la población vulnerable, contribuyendo al fortalecimiento de las políticas de prevención y a la optimización de los recursos clínicos, farmacológicos y de rehabilitación en el sistema de salud nacional.

Entendimiento del negocio

Formulación del problema

El IMSS carece actualmente de un modelo analítico predictivo que le permita anticipar con precisión la incidencia de la EP en la población mexicana. Esta limitación dificulta la planeación oportuna de recursos médicos, farmacológicos y de rehabilitación, además, reduce la capacidad de respuesta frente al crecimiento sostenido de esta enfermedad en el país, tanto en el factor de servicio como el factor económico. Al no existir una estimación, que prevenga el incremento de la enfermedad, es difícil realizar un presupuesto institucional con suficiente exactitud y reservas ante un posible aumento de casos de una enfermedad.

Contexto

La EP, segunda patología neurodegenerativa más frecuente después del Alzheimer, muestra una tendencia ascendente en México. Datos recientes del consorcio MEX-PD estiman una incidencia de 9.48 casos por cada 100,000 personas - años en mayores de 20 años, con edad promedio al diagnóstico de 59.9 años y un 21% de inicio temprano (Lázaro-Figueroa et al., 2023). Este escenario plantea retos críticos para el IMSS:

- Saturación de servicios especializados en neurología, rehabilitación y diagnóstico temprano.
- Altos costos directos en medicamentos, terapias y hospitalización, además de costos indirectos por pérdida de productividad, incapacidades y cuidados prolongados.
- Impacto social y familiar significativo, dado el carácter crónico, progresivo y discapacitante de la enfermedad, agravado por diagnósticos tardíos y casos de inicio temprano.
- Necesidad de robustecer la vigilancia epidemiológica con registros nacionales consistentes y modelos analíticos que permitan anticipar la demanda de servicios.
- Oportunidad de personalizar la atención mediante estudios genéticos y ambientales específicos de la población mexicana.

Objetivos

Los principales objetivos que se tienen en este proyecto es el desarrollar un modelo supervisado que prediga la incidencia futura de la enfermedad de Parkinson en México, con base en datos epidemiológicos históricos del IMSS (2014–2024).

Los objetivos específicos que se tienen son principalmente:

- Identificar patrones epidemiológicos relevantes en el periodo analizado.
- Generar proyecciones por entidad federativa para apoyar la planificación regional.
- Enriquecer el dataset con información complementaria que permita estimar de manera más integral la carga de la enfermedad.
- Detectar posibles factores de riesgo asociados a mayor incidencia.
- Proporcionar información que apoye la toma de decisiones estratégicas en salud pública y asignación de recursos.

Preguntas clave

Para el proyecto se desarrollaron preguntas que serían clave para la elaboración de un modelo útil que permita a las instituciones de salud públicas determinar y predecir la futura incidencia de casos de pacientes con EP.

- ¿Cuál será la tendencia de casos de Parkinson en los próximos años en México?
- ¿Qué patrones epidemiológicos se observan en los datos históricos del IMSS?
- ¿Cuáles son las deficiencias y limitantes del dataset? ¿La información tiene datos faltantes?
- ¿De qué manera puede el dataset enriquecerse con información complementaria para ampliar la comprensión de la carga de la enfermedad?
- ¿Qué factores de riesgo podrían anticipar mayor incidencia o progresión por entidad federativa?
- ¿Cómo puede esta información apoyar la planeación de recursos y estrategias de salud pública en el IMSS?

Involucrados

- División de Investigación del IMSS: Responsables de aportar datos, validar resultados y generar reportes oficiales, representante: Dra. Ruth Pérez Hernández
- Asesor técnico: Responsable de supervisar el proyecto, proveer guía técnica sobre los acercamientos propuestos y soporte en la asignación de recursos, representante: Dra. Grettel Barcelo Alonsó.
- Equipo de trabajo: Estudiantes de maestría que trabajan en conjunto para diseñar y realizar las investigaciones, estudios y experimentos para aproximar una propuesta de solución para la problemática.
- Entidades externas: Instituciones que proveen información pública para complementar la información de nuestro dashboard, representantes: Instituto Nacional de Neurología y Neurocirugía, Instituto Nacional de Estadística y Geografía (INEGI).

Entendimiento de los datos y descripción de los datos

El dataset está conformado por series históricas semanales de registros epidemiológicos del IMSS y otras instituciones públicas del país (2014–2024), con cobertura a nivel nacional y por entidad federativa. Los datos provienen de boletines de la División de Vigilancia Epidemiológica y reflejan tanto los nuevos casos como los acumulados de diversas enfermedades neurológicas y trastornos mentales, con énfasis en la enfermedad de Parkinson (EP).

Esta base de información constituye el insumo principal para caracterizar patrones epidemiológicos y desarrollar modelos predictivos que permitan anticipar el comportamiento de la enfermedad en México, facilitando la planeación estratégica y la toma de decisiones en salud pública.

El dataset provee claros periodos de tiempo, incluso información específica de entidades federativas, esto nos permite complementar la información del dataset utilizando información de otras instituciones públicas del país, otros boletines informativos del sistema de salud, incluso con boletines de cada entidad federativa. Esto con el fin de enriquecer y mejorar los resultados.

Técnica de ML

Se planea aplicar modelos supervisados de aprendizaje automático que permitirá analizar patrones históricos y generar proyecciones de incidencia futura de la EP en México, así como datos de valor que permitan la toma de decisiones para los sistemas de salud. La intención de esto es comparar diferentes resultados para obtener el mejor resultado para la predicción y proyección. La elección de este enfoque se justifica porque:

- Los datos están estructurados y etiquetados por semana, año, entidad y diagnóstico, lo que facilita el entrenamiento supervisado.
- La técnica permite identificar tendencias temporales y regionales en la evolución de la enfermedad.
- Las proyecciones generadas podrán servir como herramienta de planeación operativa para el IMSS en la asignación de recursos médicos, farmacológicos y de rehabilitación.

Identificación de variables

Para este dataset se tienen las siguientes variables:

- **Año:** periodo de registro (2014–2024).
- **Semana:** número de semana epidemiológica.
- **Entidad:** Estado de la República Mexicana.
- **Padecimiento:** diagnóstico reportado.
- **Valor:** número de casos asociados al diagnóstico en esa semana/entidad.
- **Ax_001, Ax_002, Ax_003:** variables auxiliares que corresponden a acumulados por sexo o categorías de reporte y año de referencia.
- **Pág./Cuadro:** metadatos de ubicación dentro del boletín epidemiológico.

Convenios

Para este proyecto se está trabajando en conjunto con el IMSS. Se nos proporcionó información pública sobre la salud mental de la población que ha sido atendida en

las diferentes clínicas del país que haya sido detectado, o que cuente ya con la enfermedad con un avance, con Parkinson.

Hallazgos importantes de análisis exploratorio

Durante la primera fase del proyecto se realizó el análisis exploratorio de los datos proporcionados por el IMSS, con el fin de lograr una mejor comprensión del comportamiento de los casos en pacientes con EP en México y sus diferentes entidades.

Inicialmente, se recibe la información con columnas con nombres que no aportan información relevante y se optaron por eliminarlas, dejando solamente las más importantes.

	Año	Semana	Pag.	Cuadro	No_01	Entidad	No_02	Padecimiento	Ax_001	Ax_002	Ax_003	No_03	Valor	No_04
0	2014	sem02	57	CUADRO 17.	NaN	Aguascalientes	NaN	Depresión CIE-10 ^a REV.F32	2014	0	Sem.	NaN	1	NaN
1	2014	sem02	57	CUADRO 17.	NaN	Aguascalientes	NaN	Depresión CIE-10 ^a REV.F32	2014	Acum.	H	NaN	1	NaN
2	2014	sem02	57	CUADRO 17.	NaN	Aguascalientes	NaN	Depresión CIE-10 ^a REV.F32	2014	Acum.	M	NaN	0	NaN
3	2014	sem02	57	CUADRO 17.	NaN	Aguascalientes	NaN	Enfermedad de Parkinson CIE-10 ^a REV. G20	2014	0	Sem.	NaN	0	NaN
4	2014	sem02	57	CUADRO 17.	NaN	Aguascalientes	NaN	Enfermedad de Parkinson CIE-10 ^a REV. G20	2014	Acum.	H	NaN	0	NaN

Fig. 1. Dataset inicial

Limpieza de dataset

Estructura y limpieza: se recortan espacios en nombres de columnas y se eliminan variables irrelevantes (Pág., Cuadro, No_, Ax_00) que no aportan al análisis.

Renombrado: se renombran campos clave (Ax_003 → Sexo, Valor → Casos) para mejorar la legibilidad.

Filtrado: se eliminan filas agregadas (Entidad = "TOTAL") para evitar doble conteo y se unifican denominaciones territoriales ("Distrito Federal" → "Ciudad de México").

Normalización de categorías: se estandariza Sexo (sin puntos, sin espacios y en mayúsculas) y se limpia la columna Padecimiento (eliminando saltos de línea, espacios múltiples y corrigiendo el pegado con "CIE").

Conversión numérica: la columna Casos se transforma a formato numérico sin imputar valores, preservando nulos para su posterior tratamiento.

Dejando finalmente el dataset con sus respectivas transformaciones con información relevante.

	Año	Semana	Entidad	Padecimiento	Sexo	Casos
3	2014	sem02	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	SEM	0
4	2014	sem02	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	H	0
5	2014	sem02	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	M	0
12	2014	sem02	Baja California	Enfermedad de Parkinson CIE-10a REV. G20	SEM	1
13	2014	sem02	Baja California	Enfermedad de Parkinson CIE-10a REV. G20	H	1
14	2014	sem02	Baja California	Enfermedad de Parkinson CIE-10a REV. G20	M	0
21	2014	sem02	Baja California Sur	Enfermedad de Parkinson CIE-10a REV. G20	SEM	0
22	2014	sem02	Baja California Sur	Enfermedad de Parkinson CIE-10a REV. G20	H	0
23	2014	sem02	Baja California Sur	Enfermedad de Parkinson CIE-10a REV. G20	M	0
30	2014	sem02	Campeche	Enfermedad de Parkinson CIE-10a REV. G20	SEM	0

Fig. 2. Dataset inicial tras transformaciones y limpieza

Posteriormente, se realiza una reestructuración del dataset, normalizando el 'Sexo' para evitar perder registros por variantes tipográficas: se recortaron espacios, se removió el punto final (Sem. → SEM), se eliminaron espacios intermedios y se convierte a mayúsculas. Luego se filtraron únicamente las categorías SEM, H, M sobre la columna normalizada (Sexo_norm).

La columna Casos se forzó a numérica y Semana_num se obtuvo extrayendo el número de la columna textual Semana. Posteriormente, el dataset se reestructuró con un pivote por Año, Semana_num, Entidad y Padecimiento, usando Sexo_norm como columnas, consolidando en tres métricas:

Nuevos_Casos (antes SEM): casos reportados en la semana.

Acum_H (antes H): acumulado en hombres a la fecha de la semana.

Acum_M (antes M): acumulado en mujeres a la fecha de la semana.

Se realiza una imputación a las semanas faltantes detectadas en el dataset, se detectan los outliers y se realizan las correcciones a las semanas con afectaciones.

Estas correcciones dan como resultado el dataset corregido, teniendo en cuenta las transformaciones y generación de métricas.

	Año	Semana_num	Fecha	Entidad	Padecimiento	Nuevos_Casos	Acum_H	Acum_M	Fecha_inicio	Fecha_fin
0	2014	2	2014-01-05	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	0	0	0	2014-01-05	2014-01-11
1	2014	3	2014-01-12	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	0	0	0	2014-01-12	2014-01-18
2	2014	4	2014-01-19	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	1	0	1	2014-01-19	2014-01-25
3	2014	5	2014-01-26	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	0	0	1	2014-01-26	2014-02-01
4	2014	6	2014-02-02	Aguascalientes	Enfermedad de Parkinson CIE-10a REV. G20	0	0	1	2014-02-02	2014-02-08
...	...	...	...	...	...	...	...	...	...	...

Fig. 3. Dataset corregido y final

Gráficos relevantes obtenidos durante análisis

El dataset corregido nos permite conocer a detalle la información más relevante sobre los casos.




Fig. 4. Serie temporal nacional - Nuevos Casos

Este gráfico, de serie temporal, condensa la historia del fenómeno: muestra tendencia y estacionalidad, resalta picos atípicos y evidencia huecos o cambios de registro; el suavizado ayuda a separar señal de ruido para comunicar eventos

nacionales y guiar el modelado. El gráfico muestra el alza y baja de los casos en el país al paso de los años, mostrando un sesgo y con una distribución asimétrica hacia la derecha muchas semanas con valores bajos y colas largas con picos. Asimismo, se muestran valores atípicos como en la fecha del 2023-09-24, en donde estos picos son concentrados en pocos puntos en la serie y solamente en unas entidades. Para la verificación de estos casos atípicos, se verificó con el boletín epidemiológico, detectando que las lecturas son reales y no errores de captura.




Fig. 5. Serie de tiempo con outliers.

Se realizó también un diagnóstico temporal de la serie (STL/ACF), logrando detectar que existe una tendencia ascendente de casos durante los años 2014 - 2019, seguido de una caída grande en el 2020 - 2021 para más tarde aumentar nuevamente durante 2022 - 2024. Se identificó que la información cuenta con una estacionalidad débil.

El gráfico ACF muestra una autocorrelación positiva, siendo persistente a rezagos, indicando no estacionalidad. Gracias a estos gráficos es que se detecta la estructura temporal de la información y de los choques puntuales para generar el preprocesamiento adecuado, elección del modelo a utilizar y sus especificaciones.




Fig. 6. Gráficos STL




Fig. 7. Gráfico ACF

¿Existe correlación entre las variables?

Sí. En las variaciones semanales agregadas a nivel nacional encontramos correlación clara entre la variable “dependiente” Nuevos_Casos y los “independientes” acumulados por sexo: con Acum_M es alta ~ 0.92 y con Acum_H moderada ~ 0.60 ; además, Acum_H y Acum_M entre sí también están fuertemente correlacionados ~ 0.84 . Esto es coherente: los acumulados se actualizan precisamente con los casos nuevos.




Fig. 8. Heatmap de correlación de variables.

ANOVA

En esta sección del proyecto se realizaron diferentes análisis para comprender el comportamiento de los datos, como los casos por sexo durante los años y en qué entidades se ve mayores afectaciones. Se realizaron 3 análisis, siendo los siguientes:

ANOVA - diferencias de casos por entidad

```
estado = {
    accepted: sub_df
    for accepted, sub_df in df_final.groupby("Entidad")["Nuevos_Casos"]
}

from scipy import stats
import sys

estados_list = []
for es in estado:
    estados_list.append(estado[es])
f_statistic, p_value = stats.f_oneway(*estados_list)
print(f'Estadístico F: {f_statistic}')
print(f'Valor p: {p_value}')
if p_value < sys.float_info.epsilon:
    print("P es muy pequeño menor a lo procesado por el sistema, por eso se muestra 0")
else:
    print("P es normal")
```

Estadístico F: [549.28271561]

Valor p: [0.]

P es muy pequeño menor a lo procesado por el sistema, por eso se muestra 0

Fig. 9. Script de diferencias de casos por entidad

El resultado de este análisis fue que el valor P siendo tan pequeño indica que se rechaza la hipótesis nula, significando que está fuertemente relacionado con la variable dependiente al ser mucho menor que 0.05. Donde **F = 300.96** y **p < .05** indicando una correlación directa entre entidades.

ANOVA - diferencia de casos por año

```
años = {
    accepted: sub_df
    for accepted, sub_df in df_final.groupby("Año")["Nuevos_Casos"]
}
```

```
from scipy import stats
años_list = []
for a in años:
    años_list.append(años[a])
f_statistic, p_value = stats.f_oneway(*años_list)
print(f'Estadístico F: {f_statistic}')
print(f'Valor p: {p_value}')
```

Estadístico F: [51.87460751]

Valor p: [1.42830632e-103]

Fig. 10. Script diferencias casos por año

Este resultado nos indica que las medias no son iguales y se tiene que capturar año y estacionalidad.

ANOVA - diferencias de casos por sexo

```
from scipy import stats

# Preparar listas numéricas por sexo desde df_final
sexos_list = [
    df_final['Acum_H'].dropna(),
    df_final['Acum_M'].dropna()
]

# ANOVA de una vía para comparar hombres vs mujeres
f_statistic, p_value = stats.f_oneway(*sexos_list)

# Resultados
print(f"Estadístico F: {f_statistic:.4f}")
print(f"Valor p: {p_value:.6f}")

if p_value < 0.05:
    print("Diferencia estadísticamente significativa entre hombres y mujeres (p < 0.05).")
else:
    print("No hay diferencia estadísticamente significativa (p ≥ 0.05).")
```

Estadístico F: 54.7664

Valor p: 0.000000

Diferencia estadísticamente significativa entre hombres y mujeres (p < 0.05).

Fig. 11. Script para diferencia de caso por sexo

Estos resultados nos indican que las medias por sexo difirieron en donde los tests nos muestran diferencias estadísticamente significativas en los casos de Parkinson entre entidades (**F≈300.96**, **p≈0**), años (**F≈42.76**, **p≈1.35e-84**) y sexo (**F≈54.66**, **p≈1.46e-13**). Siendo así, se define que la carga de los casos no es homogénea, ya

que esta varía por estado, cambia en el tiempo y difiere entre hombres y mujeres, teniendo una relación directa entre estos y la variable objetivo.

Adición de variables exógenas.

Para enriquecer el dataset obtenido y la información presentada en el dashboard, se optó por la adición de variables exógenas para obtener un mejor contexto sobre la enfermedad. Las variables añadidas fueron:

- *Otorgamiento_consulta*: Eficacia de otorgamiento de consulta médica programada.
- *Procedimientos_diagnósticos_alta_especialidad*: Porcentaje de procedimientos diagnósticos de alta especialidad realizados en el área de Neurociencias y neurocirugía.
- *Egresos_mejoría_curación*: Porcentaje de egresos hospitalarios por mejoría y curación en el área de Neurociencias y neurocirugía.
- *Ocupación_hospitalaria*: Porcentaje de ocupación hospitalaria en el área de Neurociencias y neurocirugía.
- *Referidos_instituciones_públicas*: Porcentaje de pacientes referidos por instituciones públicas en el área de Neurociencias y neurocirugía.
- *Investigadores_alto_nivel*: Porcentaje de investigadores institucionales de alto nivel en el área de Neurociencias y neurocirugía.
- *Eficacia_formación_médicos_especialistas*: Eficacia a la formación de especialistas en el área de Neurociencias y neurocirugía.
- *Profesionales_salud_educación_continua*: Porcentaje de profesionales de la salud que concluyeron cursos de educación continua en el área de Neurociencias y neurocirugía.




Fig. 12. Correlación de variables exógenas con variable objetivo

Este gráfico muestra cómo se correlacionan las nuevas variables con nuestra variable objetivo una vez que se realizaron las transformaciones necesarias para limpiar y ajustar a estas mismas.




Fig. 13. Distribución comportamiento de variables.

Este gráfico muestra el comportamiento de las variables y su distribución para verificar si se requiere realizar transformaciones para mejorar su comportamiento.




Fig. 14. Distribución de comportamiento de variables post-transformación.

Con esta transformación, vemos que, en su mayoría, las distribuciones de nuestras variables se asemejan más a la distribución normal.

Modelos generados y selección de modelo final

Durante el proceso de modelado se desarrollaron dos líneas de trabajo complementarias:

1. Modelos supervisados (Random Forest, XGBoost, LightGBM y HistGradientBoost).
2. Modelos de series de tiempo (SARIMA, UCM, ETS/Holt, STL+ARIMA y Prophet).

Para ser capaces de comparar directamente estos modelos, utilizaremos las siguientes métricas:

- MAE: Error absoluto medio, nos permite determinar en promedio por cuanto se equivocó nuestra predicción del valor real.
- MASE: Error medio absoluto escalado, evalúa la precisión del modelo, y al escalar los resultados no se ve afectado por observaciones atípicas.
- sMAPE: Error Simétrico Porcentual Medio: Nos da una evaluación de la precisión del modelo, nos dice de manera porcentual la diferencia relativa entre los valores reales y las predicciones.

Modelos generados.

Durante la realización de este proyecto se entrenaron diversos modelos, con dos técnicas distintas, a continuación se presentan las métricas obtenidos de todos los modelos entrenados:

Modelo	MAE	MASE	sMAPE	Tiempo de Entrenamiento
Modelos Supervisados				
Random Forest	34.052173	1.650073	22.54576 %	0.1838225 s.

XGBoost	42.930434	2.080289	29.83871 %	0.3518251 s.
LightGBM	29.782608	1.443182	19.27049 %	0.1474909 s.
Hist Gradient Boost	44.869565	2.174254	31.44043 %	2.64856169 s.
Modelos de Series de Tiempo				
SARIMA ajustado v4	16.502000	0.397000	11.25700 %	97.677000 s.
SARIMA ajustado v3	16.822000	0.405000	11.46000 %	70.550000 s.
SARIMA ajustado v1	17.026000	0.410000	11.57800 %	22.120000 s.
SARIMA ajustado v2	17.029000	0.410000	11.58300 %	26.377000 s.
SARIMA base	17.510000	0.422000	11.82000 %	21.924000 s.
UCM	17.877000	0.430000	12.15700 %	1.942000 s.
ARIMA + Fourier	17.683000	0.426000	12.42400 %	0.639000 s.
Línea base ETS Holt aditivo	21.113000	0.508000	14.94400 %	0.034000 s.
STL + ARIMA	28.620000	0.689000	18.02100 %	0.308000 s.
Prophet	12.8784	0.3101	8.9718 %	0.3841 s.

Con estos resultados podemos comparar el rendimiento de cada modelo y elegir el que mejor se adecue a nuestro caso de uso:

Los modelos supervisados fueron descartados debido a que el mejor caso alcanzó un error de aproximadamente 19%, lo que los hace poco confiables para producción.

Este alto error absoluto producido y el alto error porcentual es debido al error acumulado; al trabajar con una serie de tiempo, la predicción se basa en los datos anteriores, por ello, entre más predicciones hagamos, el error de los modelos supervisados será mayor, es decir, estos modelos están limitados al horizonte de predicciones que hagamos.

Recordando que nuestra información está segmentada en periodos semanales, y que la información mínima relevante para el IMSS es la predicción del año siguiente, nuestros modelos supervisados acumulan el error de 52 semanas, lo que genera un alto error. Sin embargo, para pocas predicciones continuas, el error es mucho menor, incluso para pocos periodos puede obtener métricas similares al mejor modelo de series de tiempo, pero debido a que los datos y predicciones son semanales, un horizonte de predicciones bajo, implica pronósticos no muy lejanos en el tiempo.

Es por ello que debido al alto horizonte de predicciones necesarias para este caso de uso, los modelos supervisados fueron descartados. A continuación se muestran datos y gráficas de cómo se acumula el error a lo largo del horizonte de predicciones para el mejor modelo supervisado.

Acumulación del Error para el mejor modelo supervisado		
LightGBM		
Número de Predicciones	MAE	sMAPE
5 Semanas	13.4	9.477601729143876 %
25 Semanas	17.28	12.132657628093657 %

52 Semanas	29.7826	19.27049 %
-------------------	----------------	-------------------




Fig. 15. Gráfico de aumento de error conforme al horizonte de predicciones

En la tabla y las gráficas podemos corroborar el comportamiento descrito, entre más iteraciones de predicciones se hagan más se acumula el error.

Finalmente, vemos de manera clara que los modelos de series de tiempo tienen un rendimiento superior al de los modelos supervisados para múltiples predicciones continuas. Dentro de todos los modelos de series de tiempo también se muestra de manera clara que el modelo Prophet mostró la mayor estabilidad, bajo error y excelente coherencia entre niveles de agregación.

Por estas razones se optó por Prophet tanto para la serie nacional como para las series por entidad federativa, aplicando la misma configuración base y ajustando el pipeline temporal.

Modelo final: Prophet

Nuestro modelo final es capaz de realizar pronósticos nacionales semanales, debido a la cantidad de información. Aun así, se trabajó para proporcionar otro modelo basado en Prophet que haga las predicciones semanales por entidad federativa, utilizando como base nuestro modelo final.

Modelo nacional (IMSS–Parkinson México)

El conjunto nacional contó con 573 observaciones semanales, divididas en 521 para entrenamiento y 52 para prueba:

- Train: 2014-01-05 2023-12-24
- Test: 2023-12-31 2024-12-22
- Total, de entidades: 32

Desempeño del modelo nacional

Métrica	Valor	Interpretación
MAE	12.878	Error absoluto bajo
RMSE	15.879	Control adecuado de picos y dispersión
sMAPE	8.97 %	Alta precisión porcentual
MASE	0.310	Mejor que el modelo Naïve ($MASE < 1$)
Tiempo total	0.492 s	Ejecución eficiente

El modelo nacional se configuró para capturar las tendencias de largo plazo y la estacionalidad anual del número de nuevos casos. La configuración final fue la siguiente.

Parámetro	Valor	Descripción técnica
-----------	-------	---------------------

Modelo	Prophet (nacional)	Serie agregada IMSS–Parkinson 2014–2024
Estacionalidad anual	9 armónicos (yearly_seasonality=9)	Captura oscilaciones estacionales amplias y recurrentes
Modo estacional	additive	Adecuado para variaciones de amplitud constante
changepoint_prior_scale	0.008	Controla la flexibilidad de la tendencia (baja variabilidad)
seasonality_prior_scale	7.9	Ajusta la fuerza de los componentes estacionales
Transformación de datos	log1p con corrección de ceros ($\tau = p5$)	Evita asimetrías y estabiliza la varianza
Frecuencia temporal	Semanal (W–SUN)	Cohorte epidemiológica por semana
Horizonte de predicción	52 semanas	Proyección anual operativa

Gráficas

La serie nacional no muestra un ascenso monótono: tras un pico temprano y caída hasta 2015, se observa una recuperación con quiebres entre 2015 y 2019, seguida de un quiebre pandémico 2020–2021 y una recuperación 2022–2024. El pronóstico a 52 semanas conserva oscilaciones estacionales en un rango intermedio, sin saltos de nivel.




Fig. 16. Gráfico modelo Prophet (serie completa)

La gráfica del período de prueba 2024 muestra que las predicciones de Prophet siguen de cerca las variaciones semanales observadas, capturando la estacionalidad y los cambios de nivel con pequeñas desviaciones en algunos picos; el error se mantiene estable ($sMAPE \approx 8.97\%$), lo que respalda su uso operativo para horizontes moderados.




Fig. 17. Prophet configuración actual — Real vs. Pronóstico

La figura de componentes del modelo Prophet (nivel nacional) muestra una tendencia con crecimiento progresivo hasta 2019, estabilidad entre 2019–2021 y reanudación del aumento a partir de 2022; la estacionalidad anual presenta picos recurrentes hacia febrero–marzo y descensos hacia fin de año, evidencia de un patrón cíclico estable capturado adecuadamente por el modelo.




Fig. 18. Gráfico de descomposición de componentes – Modelo Prophet

La figura presenta componentes complementarios del modelo nacional: la estacionalidad semanal muestra ondulaciones regulares a lo largo de las 52 semanas (picos hacia ~semana 8 y ~22–24, oscilaciones menores en el segundo semestre y valles en los bordes del año), mientras que los regresores adicionales reflejan eventos puntuales (picos aislados alrededor de 2018 y 2024) que el modelo captura como choques aditivos sin alterar la estabilidad general.




Fig. 19. Gráfico de descomposición de componentes – Modelo Prophet

Modelo por entidades federativas

Dada la heterogeneidad geográfica y epidemiológica del fenómeno, se replicó el flujo Prophet para cada una de las 32 entidades federativas. El objetivo fue evaluar la capacidad del modelo de conservar precisión y coherencia jerárquica en niveles sub nacionales, bajo los mismos parámetros globales.

El conjunto por entidades contó con 573 observaciones semanales por serie, divididas en 521 para entrenamiento y 52 para prueba:

- Train: 2014-01-05 2023-12-24
- Test: 2023-12-31 2024-12-22
- Total, de series (entidades): 32

Desempeño del modelo por entidades

Métrica	Valor	Interpretación
MAE	12.796	Error absoluto bajo
RMSE	15.587	Control adecuado de picos y dispersión
sMAPE	9.3905 %	Alta precisión porcentual
MASE	0.3325	Mejor que el modelo Naïve ($MASE < 1$)
Tiempo total	0.3449 s	Ejecución eficiente

El modelo por entidades se configuró para capturar los patrones locales (tendencia de largo plazo y estacionalidad anual) del número de nuevos casos en cada estado. La configuración final aplicada por serie estatal fue:

Parámetro	Valor aplicado	Descripción
-----------	----------------	-------------

Modelo	Prophet (por entidad)	Serie semanal independiente por estado
Estacionalidad anual	9 armónicos (yearly_seasonality=9)	Mantiene simetría con la tendencia nacional
Modo estacional	additive	Uniformidad en amplitud de oscilación
changepoint_prior_scale	0.008	Misma flexibilidad que el modelo nacional
seasonality_prior_scale	7.9	Refuerza periodicidad anual a nivel local
Transformación	log1p con truncamiento de ceros	Corrige sesgos en series con valores bajos
Frecuencia / horizonte	Semanal / 52 semanas	Consistencia metodológica

Comparación de desempeño — Nacional vs Entidades

Nivel	MAE	RMSE	sMAPE	MASE	Tiempo (s)	Modelo
NACIONAL	12.878	15.879	8.97 %	0.310	0.492	Prophet
ENTIDADES (promedio)	12.796	15.587	9.39 %	0.333	0.345	Prophet

El modelo Prophet, en sus dos niveles (nacional y por entidades), cumple los criterios de éxito definidos para el proyecto IMSS-Parkinson:

- Precisión: sMAPE $\approx$ 8,97 % (nacional) y $\approx$ 9.39 % (entidades).
- Eficiencia: latencia promedio < 0.5 s por ejecución.

- Interpretabilidad: descomposición clara de tendencia y estacionalidad anual.
- Escalabilidad: coherencia jerárquica entre niveles nacional y estatal.

Gráficas

La figura de componentes del modelo Prophet (nivel estatal) muestra una tendencia con crecimiento lineal hasta 2022; la estacionalidad anual presenta picos recurrentes hacia febrero-marzo y mayo-julio, y descensos hacia fin de año, evidencia de un patrón cíclico estable capturado adecuadamente por el modelo.





Fig. 20. Componentes de modelo Prophet – Entidades

La figura presenta componentes complementarios del modelo estatal: la estacionalidad semanal muestra ondulaciones regulares a lo largo de las 52 semanas (picos hacia ~semana 8, ~22-24, ~32-33, ~39-40), mientras que los regresores adicionales reflejan eventos puntuales (picos aislados alrededor de 2018 y 2024) que el modelo captura como choques aditivos sin alterar la estabilidad general.



Véase Fig. 19.

En síntesis, Prophet demostró ser el modelo más robusto, eficiente y reproducible para la predicción semanal de nuevos casos de Parkinson en México.

Recomendaciones clave para implementación de solución

Con el objetivo de implementar y desplegar la solución propuesta, se destacan las siguientes recomendaciones, así como se analizan y sugieren las posibilidades de despliegue,

Pipeline reproducible:

- Ingesta, limpieza, features, split temporal, entrenamiento, evaluación y exportación.
- Versionar datos/código y registrar metadatos.

Entrenamiento y despliegue:

- Docker + orquestación.
- Predicción batch semanal y opción ad-hoc.

Model Registry:

- Estados Staging, Production; promover solo si supera los umbrales.

Monitoreo y alertas:

- sMAPE/MAE rolling, distribución de errores y cobertura; alarmas por deriva y plan de fallback.

Gobernanza y seguridad:

- Accesos por rol, auditoría; checklist ético.

Operación:

- Retrain trimestral con revisión retro; documentación técnica y manual para áreas usuarias.

Acciones por stakeholders

Stakeholder	Tarea	Entregable
Dirección/Comité	Definir umbrales, frecuencia de retrain y plan de riesgos	Política MLOps
Analítica/IA	Montar pipeline, registrar modelos, CV temporal y tablero	Repo + Registry + Dashboard
Vigilancia Epidemiológica	Validar pronósticos con históricos/señales clínicas	Informe de validación
Planeación y Recursos	Usar proyecciones para recursos y campañas	Reportes operacionales
TI/Seguridad	Accesos por rol, auditoría y backups	Controles y actas

Ética/Legal	Revisar privacidad, sesgos y licitud de uso de datos	Dictamen de cumplimiento
--------------------	--	--------------------------

Plataforma de nube: análisis comparativo

Plataforma	Características
AWS (SageMaker, Lambda, Step Functions)	• Ecosistema MLOps muy completo; escalamiento granular. • Curva de aprendizaje y costos variables si hay muchas ejecuciones.
Azure (ML, AD, Power BI)	• Integración corporativa y BI; buen gobierno de identidades. • Menos flexible que AWS para pipelines altamente personalizados
GCP (Vertex AI, BigQuery, DataFlow)	• Flujo simple para notebooks, pipeline y endpoint; integración nativa con BigQuery; buen costo académico/institucional; excelente para Prophet y jobs batch. • Requiere habituarse al stack Google si el equipo viene de otros clouds.
IBM Watson	• Enfoque fuerte en gobernanza/ética; interfaz amigable.

	Menor comunidad y costos superiores en escalas grandes.
--	---


Plataforma seleccionada:

GCP (Vertex AI + BigQuery) por:

1. Rapidez para operacionalizar Prophecy y batch jobs.
2. Monitoreo/registro sencillo.
3. Buena relación costo-facilidad en contexto académico.
4. Integración natural con tableros (Looker Studio/BigQuery dashboards) y exportación a Power BI si se requiere.

Plan de despliegue (propuesto)

- A. Semana 1-2: Hardening de pipeline + dockerización + pruebas de integridad.
- B. Semana 3: Registro del mejor modelo (Prophet) y tablero de monitoreo.
- C. Semana 4: Piloto con datos recientes.
- D. Semana 5: Revisión de métricas/deriva y firma de pase a producción.
- E. Operación continua: Retrain trimestral, alertas, reporte ejecutivo.



(<https://app.clickup.com/9017383415/v/g/8cqmpfq-557>)

Análisis costo-beneficio

Análisis de costos incurridos - CRISP ML

Se analizarán los costos incurridos a través del desarrollo de la solución basados en las fases de la metodología CRISP ML, también se consideran los tiempos de cada fase de acuerdo a la utilizada en el proyecto, es decir, los costos están basados en la temporalidad real del proyecto.

Comprensión de negocios y datos

Durante la adquisición de datos y estudios del negocio, se necesitan algunos costos indirectos de los cuales no se tiene certeza. Sin embargo, es necesario destacarlos y considerarlos:

- Costo operativo del boletín semanal: El proyecto se basó en la adquisición de datos a través del boletín semanal de registros epidemiológicos del IMSS y otras instituciones públicas del país. No tenemos un costo claro de la publicación y agregación de estos datos.
- Costo de la recolección de datos: De igual manera, no tenemos una cifra clara que destina cada institución para recolectar, registrar y mantener los datos.

Costos directos:

- Director de proyecto: Se considera la presencia de un responsable del proyecto. Se consideran datos procedentes de la organización Coursera: \$43,629.00 MXN
- Científicos de datos: Se considera el sueldo de tres científicos de datos para analizar y explorar la información, se consideran los datos provistos por el Staff de la organización Coursera: \$18,045.00 MXN C/U = \$54135.00 MXN total (tres personas).
- Equipo de cómputo: Se considera un equipo de cómputo promedio: \$12000 MXN C/U = \$36000.00 MXN total.
- Internet: Se requiere conexión a internet para trabajar las fuentes de información e investigaciones = \$500.00 MXN.

Total de la fase = \$134264.00 MXN.

Duración de la fase = 2 semanas

Ingeniería de datos.

En esta fase no se consideran los costos iniciales de equipo, ya que fueron absorbidos en la fase anterior, ni se consideran los salarios, puesto que estos se

consideran mensuales y por la duración de la fase, aún entra en el primer pago salarial.

Costos directos:

- Servicios Colab: Debido a que el uso es empresarial, a menos que exista algún convenio, se utilizó Google Colab como entorno de desarrollo y pruebas del equipo, de acuerdo al listado de costos de Colab: \$1044.04 MXN C/U = \$3121.20 MXN (tres personas).
- Github: Se utilizó la plataforma de Github para llevar el registro de versiones del proyecto, según su tabla de precios para organizaciones: \$80.00 MXN C/U = \$240.00 MXN (tres personas).

Total de la fase = \$3361.12 MXN.

Duración de la fase = 2 semanas.

Ingeniería de modelos de aprendizaje automático

En esta fase se desarrollaron los modelos base y los modelos adicionales, así como experimentación extra. En esta fase ya se considera nuevamente el pago de salarios, ya que por la duración de la fase y temporalidad del proyecto el pago corresponderá en esta fase, lo mismo sucede con los servicios utilizados.

Costos directos:

- Director de proyecto: Se considera la presencia de un responsable del proyecto. Se consideran datos procedentes de la organización Coursera: \$43,629.00 MXN
- Científicos de datos: Se considera el sueldo de tres científicos de datos para analizar y trabajar los modelos, se consideran los datos provistos por el Staff de la organización Coursera: \$18,045.00 MXN C/U = \$54135.00 MXN total (dos personas).
- Internet: Se requiere conexión a internet para trabajar las fuentes de información e investigaciones = \$500.00 MXN.
- Servicios Colab: Debido a que el uso es empresarial, a menos que exista algún convenio, se utilizó Google Colab como entorno de desarrollo y pruebas del equipo, de acuerdo al listado de costos de Colab: \$1044.04 MXN C/U = \$3121.20 MXN (tres personas).
- Github: Se utilizó la plataforma de Github para llevar el registro de versiones del proyecto, según su tabla de precios para organizaciones: \$80.00 MXN C/U = \$240.00 MXN (tres personas).

Total de la fase = \$101625.12 MXN

Duración de la fase = 3 semanas

Evaluación de modelos

En esta fase debido a la temporalidad no se consideran pagos de servicios o salarios.

Total de la fase = \$0.00 MXN.

Duración de la fase = 1 semana.

Despliegue e implementación.

Ya que esta fase no se llevó a cabo, se utilizará el plan propuesto anteriormente. La temporalidad nuevamente requerirá el pago de salarios y servicios dobles, porque en este punto tenemos corriente dos meses debido a la extensión de la fase, además se cambia el número de personas en roles y se añaden servicios adicionales

- Director de proyecto: Se considera la presencia de un responsable del proyecto. Se consideran datos procedentes de la organización Coursera: \$43,629.00 MXN = \$87258.00 MXN total (dos meses).
- Científicos de datos: Se considera el sueldo de dos científicos de datos para analizar y trabajar los modelos, se consideran los datos provistos por el Staff de la organización Coursera: \$18,045.00 MXN C/U = \$36090.00 MXN (dos personas) = \$72180.00 total (dos meses).
- Ingeniero DevOps: Encargado de trabajar las herramientas de despliegue, se consideran los datos procedentes de la organización Talently: \$45120.00 MXN (Una persona) = \$90240.00 MXN total (dos meses).
- Internet: Se requiere conexión a internet para trabajar las fuentes de información e investigaciones = \$500.00 MXN = \$1000.00 MXN (dos meses).
- Servicios Colab: Debido a que el uso es empresarial, a menos que exista algún convenio, se utilizó Google Colab como entorno de desarrollo y pruebas del equipo, de acuerdo al listado de costos de Colab: \$1044.04 MXN C/U = \$3121.20 MXN (tres personas) = \$6242.40 MXN total (dos meses).
- Github: Se utilizó la plataforma de Github para llevar el registro de versiones del proyecto, según su tabla de precios para organizaciones: \$80.00 MXN C/U = 240.00 MXN (tres personas) = \$480.00 MXN (dos meses).
- Vertex AI pipeline: Pipeline de ejecución, con un costo de 0.03 dólares por ejecución, suponiendo que se realizan pruebas y test de despliegue, podrían desplegarse / ejecutarse 150 pipelines, lo que nos daría un costo de 4.5 dólares = \$90.00 mxn aproximadamente.
- Vertex AI Modelos AutoML: Entrenamiento, proporción de datos y predicciones realizadas, con un costo de 0.05 dólares por hora, se considerarán 100 horas de trabajo, que incluyen: subida de datos, entrenamiento, monitoreo del primer modelo de producción antes de liberarlos, ejecución de pruebas de rendimiento y estrés. Así como

comparación de estados del modelo a través del proceso de entrenamiento, esto nos da un costo de 5 dólares = \$100.00 MXN aproximadamente.

Total de la fase = \$257590.4 MXN.

Duración de la fase = 6 semanas.

Monitoreo y mantenimiento

Para el monitoreo y mantenimiento se considerarán la ejecución de 5 pipelines mensuales, 5 actualizaciones de datos, 1 reentrenamiento y un proceso de validación para el modelo actual respecto al anterior y comprobar el rendimiento para mantener disponible el mejor modelo, estas características nos dan un costo aproximado de:

- Vertex AI pipeline: Pipeline de ejecución, con un costo de 0.03 dólares por ejecución, suponiendo el despliegue / ejecución de 5 pipelines, lo que nos daría un costo de 0.15 dólares = \$3.00 MXN aproximadamente.
- Vertex AI Modelos AutoML: Entrenamiento, proporción de datos y predicciones realizadas, con un costo de 0.05 dólares por hora, se considerarán 10 horas mensuales de trabajo para mantener el modelo, realizar pruebas, comparar métricas y actualizar datos, esto nos da un costo de 0.5 dólares = \$10.00 MXN aproximadamente.
- Científicos de datos: Se considera el sueldo de un científico de datos para mantener y analizar el modelo de producción, se consideran los datos provistos por el Staff de la organización Coursera: \$18,045.00 MXN total por mes.
- Ingeniero DevOps: Encargado de trabajar las herramientas de despliegue, se consideran los datos procedentes de la organización Talently: \$45,120.00 MXN total por mes.

Total de la fase = \$63,178.00 MXN.

Duración de la fase = Mensual

Cabe recalcar que el mantenimiento y monitoreo no requiere la contratación de personal específico solo para ese proyecto, y estos costos son solo guías para considerar el personal necesario si es que no se cuenta con él.

Costo total del proyecto (Sin mantenimiento).

Utilizando los datos de cada fase, excluyendo el mantenimiento, ya que es un dato que no es fijo, obtenemos que el costo del proyecto hasta el primer despliegue en producción se aproxima a: \$496,840.52 MXN.

Beneficios del proyecto

A continuación se listan los beneficios más importantes del proyecto para la organización:

- Estimación de presupuestos: Con el modelo productivo, el Instituto será capaz de preparar estimaciones presupuestarias para el siguiente año fiscal de una manera más eficiente.
- Estimación de costos: Con un pronóstico confiable, la institución es capaz de considerar los costos que implica el siguiente periodo para atender la enfermedad.
- Prevención epidemiológica: Con el dashboard y el modelo de pronósticos, se pueden observar tendencias y posibles escenarios donde la enfermedad tenga picos o bajas en el país.
- Propósitos de investigación: Al tener pronósticos y tendencias claras, el instituto será capaz de destinar los recursos necesarios a ciertos eventos, lo que permitirá una mejor operación de investigación, lo que podría ayudar a entender de mejor manera las tendencias del país. Además, los datos arrojados por el modelo, pueden ser la base de investigación de otros fenómenos salubres, sociales y nacionales.
- Robustecer la información institucional: El modelo y el proyecto presentan una base para la determinación de tendencias de la enfermedad. Sin embargo, el mismo instituto puede replicar el trabajo con demás enfermedades y reconocer las carencias de información que pueden presentar los sistemas de salud, y desde ese conocimiento abordar el problema y robustecer la cantidad y calidad de información que recolecta el sistema de salud.
- Atención constante: Al tener un modelo predictivo que requiere mantenimiento de manera indirecta, el instituto se ve en la necesidad de mantener en constante atención las tendencias de la enfermedad.
- Innovación institucional: Con este tipo de iniciativas se fortalece el uso tecnológico dentro de las instituciones de salud, y puede servir como precedente en el uso de la tecnología dentro de las instituciones.

Riesgos y desafíos de la solución

Los principales riesgos y desafíos que se presentaron en el desarrollo del proyecto fueron los modelos y sus ajustes, siendo los más críticos la calidad de los datos y el modelo propuesto. Se busca lograr mitigar un riesgo gracias a las buenas prácticas de MLOps y gobernanza de datos mediante el retrain automático de modelos, control de versiones y auditorías para identificar sesgos o alteraciones que puedan ocasionar que se malinterprete la información.

Riesgos con los datos

Tipo de riesgo / desafío	Descripción
Calidad y completitud de datos	Los boletines epidemiológicos presentan semanas con variaciones o registros faltantes, generando un sesgo en la información.
Desbalance territorial	Algunas entidades o periodos tienen menos registros, pudiendo afectar la estabilidad del modelo.
Definición de variables	La definición de variables de forma correcta, mostrando columnas con información relevante y única.
Granularidad y agregación	Los datos se encuentran a nivel semanal y estatal, limitando el análisis

Riesgos con prueba, confianza y desempeño

Para este apartado, el principal desafío que se encontró fue el de trabajar con series temporales. Esto generó un gran retrabajo en nuestros modelos para ajustarlos de manera eficiente y consistente para obtener resultados significativos y generar predicciones más concretas.

Tipo de riesgo / desafío	Descripción
--------------------------	-------------

Validación del modelo	El modelo Prophet tuvo varias modificaciones en su comportamiento debido a datos. Se tuvieron que hacer varias pruebas con diferentes valores para encontrar el más acertado.
Deriva del modelo	Cambios en el comportamiento epidemiológico puede degradar el rendimiento (pandemias o modificaciones)
Dependencia de patrones históricos	Al ser un modelo de series de tiempo, Prophet asume continuidad en la tendencia y estacionalidad
Sobre ajustes	Al tener un modelo sobre ajustado, el modelo puede tener complicaciones para adaptarse a nuevos escenarios.
Dificultad para interpretar resultados	Los resultados pueden ser poco claros, se necesita que sea revisado y validado por expertos y detectar correctamente tendencias y predicciones.

Los beneficios principales de este modelo robusto que se trabajó en este proyecto es principalmente el detectar tendencias y realizar predicciones más acertadas en cuanto a la EP. El desarrollo del modelo será beneficioso para las instituciones de salud públicas y privadas para saber incluso la ocupación que tendrán en sus hospitales, pudiendo preparar a más médicos para volverse especialistas en esta enfermedad y poder trabajar mejor con los pacientes, pudiendo recetar mejores medicamentos y entregar una mejor atención en las consultas y seguimientos.

Conclusiones

Gracias a este proyecto es que se pudo comprender el funcionamiento de las series de tiempos en pipelines de ML. El desarrollo de estos modelos y la comparación, entre otros, fue algo que dio grandes resultados para analizar comportamientos de los datos con diferentes métodos y llegar a uno solo que proporcione la información más completa sin tanta pérdida de información importante para realizar proyecciones y detectar anomalías.

Durante el proyecto se presentaron diferentes complicaciones con los lags y la inclusión de variables exógenas, así como la importancia de los componentes de PCA. Estos fueron retos que se superaron y manejaron de acuerdo a lo más conveniente para el caso de uso, así se lograron obtener datos acertados que permitieron generar un modelo eficiente con la información disponible, y con la posibilidad de ejecutarlo en producción y obtener resultados favorables.

Los modelos de series Nacionales y Entidades (estatales) desarrollados con Prophet alcanzaron en promedio un sMAPE $\approx 9\%$, un MASE de 0.313 y con una latencia < 0.4 s, demostrando un desempeño consistente y siendo apto para producción. Para obtener el mejor desempeño y se necesita acompañar de un esquema de monitoreo y retraining sistemático para detección de outliers y poder trabajar en ellos para obtener resultados más eficientes. La viabilidad operativa y técnica tienen un mejor desarrollo e integración gracias al pipeline de MLOps reproducible, garantizando trazabilidad, seguridad y actualización continua.

Asimismo, existe un margen de mejora al poder incluir variables exógenas, y/o modelos híbridos y gestión de cerros/outliers. El pipeline generado gracias a MLOps y un monitoreo de deriva, es que el sistema es sostenible y trazable. Para el proyecto se realizó un análisis de las diferentes plataformas en la nube que puedan ayudar con el monitoreo y escalabilidad del modelo para su implementación y seguimiento. Se optó por GCP gracias a su equilibrio entre facilidad, costos y escalabilidad para el proyecto desarrollado. El rendimiento que se obtuvo logra satisfacer los criterios de precisión, cumpliendo con la eficiencia computacional y la reproducibilidad esperadas.

El tiempo de ejecución es inferior a medio segundo, por lo que su implementación en producción es factible y permite actualizaciones semanales sin comprometer los recursos computacionales. Si bien los resultados actuales del modelo son sólidos, existe margen de mejora al incorporar variables exógenas y explorar enfoques híbridos, lo que favorecerá un aprendizaje más robusto y mejores métricas.

Esto permitirá aumentar la precisión a nivel local y fortalecer la detección de anomalías. En síntesis, el proyecto supuso un reto relevante por el uso de series de tiempo y la comparación de múltiples modelos para seleccionar la mejor alternativa. Asimismo, la evaluación de distintas plataformas permitió identificar el servicio más

viable para implementar, evolucionar y monitorear la solución, con miras a proyecciones más precisas.

Referencias

1. Dorsey, E. R., & Bloem, B. R. (2018). The Parkinson pandemic—a call to action. *JAMA Neurology*, 75(1), 9–10. <https://doi.org/10.1001/jamaneurol.2017.3299>
2. Enfermedad de Parkinson - Síntomas y causas - Mayo Clinic. (2025). Mayoclinic.org; <https://www.mayoclinic.org/es/diseases-conditions/parkinsons-disease/symptoms-causes/syc-20376055>
3. GBD Parkinson's Disease Collaborators. (2018). *Global, regional, and national burden of Parkinson's disease, 1990–2016: a systematic analysis for the Global Burden of Disease Study 2016. The Lancet Neurology*, 17(11), 939–953. [https://doi.org/10.1016/S1474-4422\(18\)30295-3](https://doi.org/10.1016/S1474-4422(18)30295-3)
4. IMSS. (2024, 8 de octubre). *IMSS-Bienestar brinda atención médica a 53.2 millones de personas en 28 estados*. Instituto Mexicano del Seguro Social. <https://www.imss.gob.mx/prensa/archivo/202410/409>
5. Lázaro-Figueroa, A., Reyes-Pérez, P., Morelos-Figaredo, E., Guerra-Galicia, C. M., Estrada-Bellmann, I., Salinas-Barboza, K., Matuk-Pérez, Y., Gandarilla-Martínez, N. A., Oropeza, D., Caballero-Sánchez, U., Montés-Alcántara, P., López-Pintor, A., Angulo-Arrieta, A. P., Flores-Ocampo, V., Espinosa-Méndez, I. M., Zayas-Del Moral, A., & Ruiz-Contreras, A. E. (2023). *Clinical and genetic insights of Parkinson's disease in a Mexican cohort: Highlighting Latino's diversity [Preprint]*. medRxiv. <https://doi.org/10.1101/2023.08.28.23294700>
6. La enfermedad de Parkinson: causas, síntomas y tratamientos. (2023). National Institute on Aging. <https://www.nia.nih.gov/espanol/parkinson/enfermedad-parkinson-causas-sintomas-tratamientos>
7. *Precios de los servicios pagados de Colab.* (s. f.). <https://colab.research.google.com/signup?hl=es-419>
8. *Pricing · Plans for every developer.* (2025). GitHub. <https://github.com/pricing>
9. Staff, C. (2025, 6 enero). *¿Cuánto ganan los analistas de datos? Guía salarial 2025*. Coursera. https://www.coursera.org/mx/articles/how-much-do-data-analysts-make-salary-guide?utm_medium=sem&utm_source=gg&utm_campaign=b2c_latam_x_multi_ftcof_career-academy_cx_dr_bau_gg_pmax_gc_s1_es_m_hyb_25-09_x&campaignid=23013457628&adgroupid=&device=c&keyword=&matchtype=&network=x&devicemodel=&creativeid=&assetgroupid=6609642748&targetid=&ex

[tensionid=&placement=&gad_source=1&gad_campaignid=23039506486&gbr aid=0AAAAADdKX6ZjPGAP-JOMgCZ5yUwOoeOCU&gclid=CjwKCAiAIMHIBhAcEiwAZhZBUr7cEbNidIVU6ksJCrbuFT7yq_KCWdVKqTIZgE5fD4xM-SHPVElcBoCJ_UQAvD_BwE](https://www.google.com/adsense/adsense?placement=&gad_source=1&gad_campaignid=23039506486&gbr aid=0AAAAADdKX6ZjPGAP-JOMgCZ5yUwOoeOCU&gclid=CjwKCAiAIMHIBhAcEiwAZhZBUr7cEbNidIVU6ksJCrbuFT7yq_KCWdVKqTIZgE5fD4xM-SHPVElcBoCJ_UQAvD_BwE)

10. Talently. (s. f.). *Salario de un DevOps en Mexico*. Salario de un DevOps En Mexico. <https://talently.tech/herramientas/mexico/salario/developer/devops>
11. Vertex AI platform. (s. f.). Google Cloud. https://cloud.google.com/vertex-ai?utm_source=google&utm_medium=cpc&utm_campaign=latam-MX-all-es-dr-SKWS-all-all-trial-b-dr-1710136-LUAC0020219&utm_content=text-ad-none-any-DEV_c-CRE_654757056677-ADGP_Hybrid+%7C+SKWS+-+BRO+%7C+txt+-+AIML-Generative+AI-Vertex+AI-MX-KWID_24136961-kwd-24136961&utm_term=KW_vertex-ST_Vertex&gclid=CjwKCAiAIMHIBhAcEiwAZhZBUr7cEbNidIVU6ksJCrbuFT7yq_KCWdVKqTIZgE5fD4xM-SHPVElcBoCJ_UQAvD_BwE#pricing