


Instituto Tecnológico y de Estudios Superiores de Monterrey



Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador: Análisis y Pronóstico Epidemiológico de la Enfermedad de Alzheimer en México (2014–2024)

Actividad 7. Resumen ejecutivo

Equipo 22:

Jorge Steven Reyes Londono A01794421

Pablo Yamamoto Magaña A01022382

Aarón Cortés García A01730451

Profesores:

Dra. Grettel Barceló Alonso

Dr. Luis Eduardo Falcón Morales

09/11/2025

ACTIVIDAD 7. RESUMEN EJECUTIVO

Síntesis del Problema.

El envejecimiento poblacional en México representa uno de los retos estructurales más críticos para el Sistema Nacional de Salud. La demencia afecta a aproximadamente 57 millones de personas a nivel mundial, de las cuales entre 60% y 70% corresponden a casos de Alzheimer. En América Latina, la situación es especialmente preocupante: entre 75% y 90% de las personas con trastornos neurológicos no reciben tratamiento oportuno, evidenciando deficiencias críticas en capacidad de detección temprana y planificación de recursos.

El Instituto Mexicano del Seguro Social (IMSS), institución de seguridad social más grande de América Latina con responsabilidad histórica de garantizar el derecho a la salud de la población mexicana, enfrenta un desafío epidemiológico creciente. Los datos del Boletín Epidemiológico de la Secretaría de Salud (2014-2024) muestran tendencias alcistas sostenidas en la incidencia de Alzheimer, enfermedad neurodegenerativa que requiere atención médica especializada, insumos costosos y cuidados prolongados.

La ausencia de herramientas predictivas robustas impide al IMSS anticipar con precisión la demanda futura de servicios médicos, personal especializado y recursos económicos necesarios para atender esta patología. Esta limitación genera ineficiencias operativas, sobreasignación o escasez de recursos según la entidad federativa, y pérdida de oportunidades para diagnósticos tempranos que reduzcan costos a largo plazo.

El problema central identificado es: ¿Cómo puede el IMSS anticiparse con precisión a la demanda de servicios para pacientes con Alzheimer a nivel nacional y por entidad federativa, utilizando datos epidemiológicos históricos para optimizar la asignación de recursos y mejorar la calidad de atención?

La solución propuesta consiste en desarrollar modelos de Machine Learning que generen pronósticos confiables de incidencia de Alzheimer con horizontes de 13, 26 y 52 semanas, desagregados por entidad federativa y género, acompañados de métricas de precisión (MASE, sMAPE, RMSE) que permitan establecer umbrales de alerta para toma de decisiones basada en datos.

Hallazgos más importantes del análisis exploratorio de datos.

El Análisis Exploratorio de Datos (EDA) fue una fase crítica que reveló la naturaleza compleja de los datos y definió la estrategia de limpieza y modelado. A continuación, se presentan los hallazgos más significativos:

1. Inconsistencia Lógica en los Datos de Origen.

El conjunto de datos presentaba dos métricas de conteo: un total de "nuevos casos semanales" reportados y los "casos acumulados" por género (hombres y mujeres). Se detectaron más de 550 instancias donde estas dos métricas entraban en conflicto; es decir, la suma de los nuevos casos calculados a partir de los acumulados de género no coincidía con el total semanal reportado.

Ante esta discrepancia, se tomó la decisión metodológica de establecer una "única fuente de verdad". Se priorizaron los datos acumulados por género por ser más granulares. A partir de ellos, se reconstruyeron las series de tiempo, aplicando las operaciones aritméticamente consistentes. Este paso fue fundamental para eliminar el ruido y las contradicciones lógicas antes de entrenar cualquier modelo.

2. Detección de Outliers Extremos en la Fuente Oficial.

A pesar de la limpieza lógica, el análisis visual y estadístico reveló la presencia de picos extremos (outliers) que no representan un patrón real. Los más notables fueron un reporte anómalo de más de 160 casos en una sola semana de abril de 2016 y otro de más de 100 casos a finales de 2023 (Figura 1).




Figura 1. Ilustración de outliers

Una validación cruzada con los boletines epidemiológicos de la Secretaría de Salud confirmó que estos errores están presentes en la fuente oficial y no son un error de transcripción. Dado que estos valores extremos sesgarían gravemente el cálculo de la tendencia y la estacionalidad, fueron tratados mediante métodos estadísticos para neutralizar su impacto desproporcionado en el modelo.

3. El Impacto Estructural de la Pandemia (COVID-19).

La serie de tiempo muestra una disrupción estructural clara a partir de marzo de 2020, coincidiendo con el inicio de la pandemia (Figura 2). Se observa una caída drástica y sostenida en los reportes, la cual, se hipotetiza, fue causada por la centralización de recursos de salud y las medidas de distanciamiento social, y no por una disminución real de la incidencia de Alzheimer. Este período de anomalía se identifica visualmente hasta mediados de 2022. Este hallazgo fue crucial, ya que nos obligó a tratar este período (2020-2022) como un evento especial y exógeno en el modelo, para evitar que esta caída "contaminara" el aprendizaje de la tendencia a largo plazo.




Figura 2. Disrupción de conteos en periodo de pandemia COVID-19

4. Evidencia de un Cambio de Régimen (Pre vs. Post-Pandemia).

Este es el hallazgo más significativo para el pronóstico. Se identificó que la serie de tiempo está visiblemente dividida en dos regímenes de comportamiento distintos:

- Pre-Pandemia (2014-2020): Muestra una tendencia clara y consistente "a la alza" en el reporte de nuevos casos.

- Post-Pandemia (2023-2025): Tras la disrupción, la tendencia no regresa a su comportamiento original. Se estabiliza en un nuevo nivel, con una pendiente de crecimiento menos pronunciada.

Este cambio de régimen representó el mayor desafío del proyecto, ya que los patrones aprendidos en los primeros 7 años no eran directamente aplicables para predecir el futuro. Esto invalidó el uso de modelos simples y fue la justificación principal para optar por modelos con mayor grado de flexibilidad.

5. Identificación de una Estacionalidad Compleja.

Finalmente, en términos de estacionalidad no se identificó un patrón consistentemente notorio, pero la serie de tiempo tampoco se percibió como completamente aleatoria. En concreto, se observó que los reportes más bajos tienden a ocurrir al inicio y final de cada año. Curiosamente, los conteos más altos se agrupan en dos períodos: un primer pico entre febrero y mayo, y un segundo pico menor entre agosto y septiembre. Reconocer esta estacionalidad de “picos” fue fundamental para trabajar en la configuración de los modelos.

Modelos Generados y Razones de la Elección del Modelo Final.

El camino hacia el modelo final implicó un proceso de eliminación, diseñado para encontrar una arquitectura que pudiera manejar las complejidades de los datos (disrupción pandémica, cambio de régimen y estacionalidad compleja) identificadas en el Análisis Exploratorio.

1. Descarte de Modelos Baseline.

En una fase inicial de *benchmarking*, se evaluaron cuatro arquitecturas distintas sobre los datos limpios:

- LSTM (Redes Neuronales): Descartado por la insuficiencia de datos. Con solo ~572 puntos (semanas), el modelo no disponía de la profundidad histórica necesaria para aprender patrones complejos y no alcanzó una convergencia adecuada.
- XGBoost (Recursivo): Aunque potente, este enfoque acumuló error rápidamente. Al generar predicciones *one-step-ahead* y luego usar esas mismas predicciones como *lags* para la siguiente semana, el error se magnificó en cada paso, fallando en capturar la tendencia a largo plazo.

- SARIMAX (Estadístico): Este modelo demostró ser demasiado rígido para la naturaleza de nuestros datos. Sus supuestos de estacionalidad fija no pudieron modelar los "picos duales" (feb-may y ago-sep) y, lo más importante, su incapacidad para manejar el "cambio de régimen" (Hallazgo 4 del EDA) lo invalidó para un pronóstico post-pandemia.
- Prophet (Basado en componentes): Este modelo (de Meta) fue seleccionado como el candidato principal. Su diseño, que trata la tendencia, la estacionalidad y los eventos (como la pandemia) de forma separada, demostró ser el más prometedor para manejar la disrupción de 2020-2022.

2. El Pivote Estratégico: De Granular a Nacional.

Una vez seleccionado Prophet, la hipótesis inicial fue desarrollar un modelo de máxima granularidad (32 modelos, uno por entidad federativa). Sin embargo, este enfoque fracasó:

- Dispersión de Datos (Sparsity): A nivel estatal, la mayoría de las series de tiempo estaban dominadas por registros en cero. Esta "dispersión" impedía al modelo encontrar una "señal" estadística (tendencia o estacionalidad) confiable, resultando en pronósticos planos.
- Decisión Metodológica: Se tomó la decisión de pivotar hacia un modelo agregado a Nivel Nacional. Al sumar todas las entidades, el "ruido" individual se canceló, revelando una serie de tiempo robusta, con patrones claros y estadísticamente significativa.

3. Optimización y Selección del Modelo Ganador.

El modelo nacional final se desarrolló bajo una estrategia clave: entrenar únicamente con los datos de 2014-2022. Esta decisión (respaldada por la experimentación) permitió al modelo aprender la tendencia y estacionalidad "reales" sin contaminarse por la volatilidad extrema y el ruido de 2023-2024. El modelo ganador combina un *GridSearch* (para optimizar *seasonality_mode* y *changepoint_prior_scale*) con un ajuste manual para capturar las estacionalidades complejas identificadas en el EDA:

- ★ Estacionalidad Anual: Orden de Fourier de 30 (flexible, para capturar los picos duales).
- ★ Estacionalidad Mensual: Orden de Fourier de 5 (para capturar patrones de reporte).

Para validar su viabilidad, el modelo fue sometido a una prueba de estrés: generar un pronóstico a 3 años (2023-2025) y compararlo con los datos reales que habíamos excluido del entrenamiento (Figura 3).




Figura 3. Proyecciones de casos reales vs predicciones del modelo Prophet Nacional en prueba de estrés a 3 años (2023-2025)

Los resultados demostraron un rendimiento estable. El modelo alcanzó un “Error Porcentual Absoluto Medio” (MAPE) total de 16.34% y un “Error Absoluto Medio” (MAE) de 7.2 casos semanales (Figura 4).

Período de Evaluación	MAPE	MAE	RMSE
2023 (Año 1)	15.38%	7.81	9.35
2024 (Año 2)	17.57%	7.11	8.46
2025 (Año 3)	15.97%	6.54	8.91
Promedio Total (2023-2025)	16.34%	7.20	8.91

Figura 4. Tabla con resumen de métricas obtenidas en prueba de estrés a 3 años de pronóstico

El hallazgo crítico fue la estabilidad del error a largo plazo. A diferencia de los modelos descartados, el error no se acumuló ni "explotó" con el tiempo: el MAPE del Año 3 (15.97%) fue virtualmente idéntico al del Año 1 (15.38%).

Razón de la Elección: Se seleccionó este modelo Prophet Nacional (entrenado 2014-2022) por ser el único que demostró generalizar correctamente la tendencia fundamental de la serie, ofreciendo un pronóstico estable y con un rango de error conocido (MAPE 16.34%) en un horizonte de 3 años, haciéndolo viable como herramienta de planeación estratégica.


Recomendaciones Clave para Implementar la Solución.

Nuestras recomendaciones se basan en un enfoque pragmático y por fases, diseñado para entregar valor inmediato (con costo cero) y, al mismo tiempo, establecer las bases para un sistema de pronóstico más preciso y granular a futuro.

Fase 1: Implementación del Piloto Estratégico (Valor Inmediato).

Recomendamos la adopción inmediata del modelo nacional (MAPE 16.34%) como herramienta de planeación estratégica y macro-presupuestal, utilizando la arquitectura de costo cero ya desarrollada.

- El Flujo Operacional: La implementación no requiere inversión en infraestructura. El flujo de trabajo está diseñado para ser ejecutado localmente por un analista designado:
1. Ejecución: El analista clona el repositorio de GitHub y ejecuta el notebook de pronóstico. Gracias a la eficiencia del modelo, este proceso toma solo 2.23 segundos en un equipo estándar:
 - a. Procesador: Intel® Core™ i7-12650H (versión 2022)
 - b. Gráficos: NVIDIA® GeForce® RTX™ 3070 con 8 GB GDDR6 (105W con Dynamic Boost)
 - c. Memoria RAM: 8 GB DDR5-4800 SO-DIMM, expandible hasta 32 GB
 2. Exportación: El *script* genera un archivo `forecast_results.csv` actualizado con las predicciones para 2026 y los datos reales más recientes.
 3. Visualización: Este CSV se utiliza como la fuente de datos para el *dashboard* de Tableau ya implementado (Figura 5).






Figura 5. Visualización ejemplo del Dashboard desarrollado en Tableau

- Accionable para el IMSS: Los tomadores de decisiones pueden consumir los resultados directamente en el *dashboard*, comparando tendencias, proyecciones de casos y, crucialmente, las estimaciones de costos asociadas al pronóstico, permitiendo una asignación de presupuesto anual más informada.

Fase 2: Robustecimiento de Datos y Monitoreo (Mejora Continua).

Para superar el umbral actual del 16.34% de error, la siguiente palanca de mejora no únicamente recae en el algoritmo, sino también en la calidad y profundidad de los datos.

- Oportunidad de Gobernanza de Datos: Recomendamos iniciar un proyecto colaborativo entre el IMSS y la Secretaría de Salud. El objetivo no es "corregir" el pasado, sino estandarizar las metodologías de captura de datos a futuro, reconociendo la complejidad del reporte epidemiológico. Esto reducirá el "ruido" y mejorará la precisión de futuros modelos.
- Acumulación de la "Nueva Normalidad": El comportamiento post-pandemia es un régimen nuevo. Es crucial continuar acumulando datos (2025, 2026) y re-entrenar el modelo anualmente. Esto permitirá al modelo aprender la nueva tendencia y estacionalidad con mayor confianza, afinando su precisión con el tiempo.

Fase 3: Viabilidad de Modelos Granulares y Nube (Visión a Futuro).

El objetivo final de un pronóstico a nivel estatal sigue siendo válido, pero debe abordarse solo después de la Fase 2.

- Re-evaluación Granular: Una vez que la gobernanza de datos (Fase 2) demuestre mejoras en la calidad de los reportes estatales, se debe re-evaluar el enfoque de 32 modelos independientes.
- Justificación de la Nube: Si los modelos granulares demuestran ser viables, ese será el momento de justificar la inversión en una plataforma en la nube. La gestión de 32 modelos, su re-entrenamiento automatizado y el monitoreo sí requieren la escala de servicios como Azure (por su integración nativa con Power BI/Tableau) o AWS SageMaker (por su robusto soporte para forecasting). Invertir en esta infraestructura antes de validar la viabilidad de los datos granulares sería prematuro y financieramente ineficiente.

Análisis Costo-Beneficio.

El principal impulsor de este proyecto fue desarrollar una solución de alto impacto con una eficiencia de costos máxima. El análisis demuestra que los beneficios de una planeación informada superan drásticamente los costos incurridos, que han sido gestionados estratégicamente para ser nulos.

1. Costos Incurridos.

Fase CRISP-ML	Actividades Clave	Costos de Infraestructura y Software
1. Comprensión del Negocio	Análisis de necesidades del IMSS, definición del problema.	\$0. (Uso de laptops personales).
2. Comprensión de Datos	Adquisición de boletines epidemiológicos públicos.	\$0. (Datos públicos, software <i>open-source</i> Python/Pandas).
3. Preparación de Datos	Limpieza lógica, EDA, tratamiento de <i>outliers</i> .	\$0. (Software <i>open-source</i> Python/Pandas).
4. Modelado	<i>Benchmarking</i> (LSTM, XGB, SARIMAX), <i>GridSearch</i> y ajuste de Prophet.	\$0. (Software <i>open-source</i> Python/Prophet).
5. Evaluación	Cálculo de métricas (MAPE, RMSE) y validación de estrés (2023-2025).	\$0. (Software <i>open-source</i> Python/Scikit-learn).
6. Despliegue (Piloto)	Creación de <i>notebook</i> final, serialización del modelo, desarrollo de <i>dashboard</i> .	\$0. (GitHub Free Tier, Tableau Public/Desktop).

El costo monetario total incurrido para el desarrollo de esta prueba de concepto fue de \$0 MXN. Los recursos principales fueron el tiempo, las herramientas tecnológicas y su documentación gratuitamente disponible y el expertise del equipo de ciencia de datos / machine learning.

2. Costos de Operación y Mantenimiento (Fase 1: Piloto Local).

La arquitectura recomendada (GitHub + Ejecución Local) está diseñada para mantener los costos operativos en cero.

- Costos de Infraestructura: \$0. La ejecución del pronóstico (2.23 segundos) se realiza en hardware local, eliminando la necesidad de servicios de nube (AWS/Azure), cuyos costos (> \$1,196 USD/mes) serían desproporcionados para el uso esporádico (trimestral/semestral) de un dataset de 14KB.
- Costos de Licenciamiento: \$0. La solución depende enteramente de Python, GitHub y el dashboard de Tableau existente en el IMSS.
- Costos de Mantenimiento: \$0 (en infraestructura). El único costo de mantenimiento es el tiempo del analista (recurso interno del IMSS) para ejecutar el *notebook* periódicamente y realizar el re-entrenamiento anual.

3. Costos Potenciales Futuros (Fase 3: Implementación Granular).

Es importante presupuestar que, si las mejoras en la gobernanza de datos (Fase 2) tienen éxito y se valida la viabilidad de los 32 modelos estatales (Fase 3), la arquitectura deberá escalar a la nube.

- Justificación del Costo: Gestionar, re-entrenar y monitorear 32 modelos de forma automatizada, para alimentar un *dashboard* operativo en tiempo real, sí requiere una infraestructura en la nube.
- Estimación Presupuestal: Como referencia, si el proyecto madura a la Fase 3, los costos operativos estimados para un despliegue robusto en AWS SageMaker o Microsoft Azure ML, según el análisis de proveedores, oscilarían entre \$1,200 y \$8,600 USD mensuales, dependiendo del nivel de servicio y la frecuencia de re-entrenamiento.

4. Beneficios Potenciales.

El valor del proyecto no reside en un ahorro de costos de TI, sino en la mejora de la eficiencia en la planeación estratégica del IMSS.

- Beneficios Cuantitativos (Toma de Decisiones Informada):
 - Transición de Planeación Reactiva a Proactiva: El beneficio principal es reemplazar la intuición por un pronóstico estadístico robusto.
 - Optimización Presupuestal: El modelo, con un rango de error conocido y estable (MAPE 16.34%), alimenta directamente el *dashboard* de Tableau. Esto permite al IMSS vincular la predicción de casos a una estimación de costos (insumos, personal, medicamentos). A nivel macro, una reducción del 16.34% en la incertidumbre de la planeación presupuestal anual representa un ahorro potencial significativo al evitar la sobreasignación o escasez de recursos críticos.
- Beneficios Cualitativos (Intangibles):
 - Fundamento para la Gobernanza de Datos: El proyecto actúa como un diagnóstico. Su hallazgo más valioso es la demostración de la necesidad de estandarizar la captura de datos (Fase 2). El beneficio a largo plazo es la creación de un activo de datos más confiable para todos los futuros proyectos analíticos del IMSS.
 - Mejora de la Calidad Asistencial (Indirecta): Una mejor planeación anual (estratégica) asegura que los recursos correctos estén en el lugar correcto, mejorando indirectamente la capacidad de respuesta del Instituto y la calidad de la atención al paciente a largo plazo.
 - Activo Intelectual Reutilizable: El IMSS ahora posee un *pipeline* de forecasting validado y de costo cero, que sirve como base para futuros modelos granulares.

Riesgos y Desafíos de la Solución.

Si bien la solución recomendada (GitHub + Ejecución Local) mitiga exitosamente los altos costos y la complejidad de la infraestructura en la nube, introduce un conjunto diferente de desafíos que deben gestionarse para asegurar el éxito y la sostenibilidad del proyecto.

Los riesgos se clasifican de la siguiente manera:

1. Riesgos Relacionados con los Datos.

- Integridad de la Fuente (Riesgo Alto): El *pipeline* de predicción depende enteramente de la disponibilidad y vaciado de los Boletines Epidemiológicos

de la Secretaría de Salud. El proyecto no contempló la implementación de un *script* automático para hacer el vaciado de la información, sino que es dependiente de contar ya con un .csv con los datos recabados. Por lo tanto, se debe hacer este trabajo inicial, cuidando que se mantengan los mismos formatos, estructura y nombre de las columnas.

- Calidad de la Fuente (Riesgo Medio): Como se identificó en el EDA (Hallazgo 2), la fuente oficial presenta *outliers* y anomalías históricas. El modelo actual está diseñado para manejarlos, pero la aparición de nuevos picos anómalos (no relacionados con un patrón real) puede sesgar futuros pronósticos si no se monitorean activamente.

2. Riesgos de Prueba y Confianza (Estabilidad del Modelo).

- Deriva del Modelo (Model Drift) (Riesgo Alto): Este es el riesgo técnico más significativo. El modelo se entrenó con datos 2014-2022. El comportamiento post-pandemia (2023+) es un "nuevo régimen" que aún está en formación. Si esta nueva tendencia cambia (por ejemplo, si su pendiente de crecimiento se acelera), el pronóstico de nuestro modelo (basado en la tendencia 2014-2022) se volverá obsoleto e impreciso.
 - ◆ Mitigación: Este riesgo se gestiona mediante la Recomendación de Fase 2 (Re-entrenamiento Anual). Acumular más datos (2025, 2026) y re-entrenar el modelo es obligatorio para que siga siendo relevante.
- Riesgo de Adopción (Dependencia Manual): Al no ser una solución en la nube automatizada, el modelo depende de un analista humano para ejecutar el *notebook* y actualizar el *dashboard* de Tableau. Si esta tarea no se asigna formalmente o no se ejecuta con la periodicidad definida (ej. trimestral), el *dashboard* quedará obsoleto y el proyecto perderá su valor operativo.

3. Riesgos de Ataques.

- Seguridad del Repositorio (Riesgo Medio): Al ser una solución basada en un repositorio, existe un riesgo si la gestión de accesos no es estricta. Un atacante con acceso podría introducir código malicioso en el *notebook* de pronóstico.
- Seguridad del Endpoint Local (Riesgo Bajo): A diferencia de una solución en la nube, el modelo no está expuesto a ataques de red (DDoS, inyección SQL). El riesgo se transfiere a la seguridad de la máquina local del analista que ejecuta el *script*. Este riesgo se considera bajo y es gestionado por las políticas de seguridad de TI existentes en el IMSS.

4. Riesgos de Cumplimiento.

- Manejo de Datos (Fase 1 - Riesgo Bajo): En la Fase 1 (Piloto Nacional), este riesgo es mínimo. El modelo utiliza datos agregados a nivel nacional, que son de carácter público y no contienen información personal identificable (PII).
- Manejo de Datos (Fase 3 - Riesgo Alto): Este riesgo se activará si el proyecto avanza a la Fase 3 (modelos granulares) y va más allá. El manejo de datos a nivel estatal y por género, aunque agregado, debe ser auditado para asegurar el cumplimiento estricto de la Ley Federal de Protección de Datos Personales en Posesión de los Particulares (LFPDPPP) y las normativas internas de manejo de información sensible.